

Knowledge Discovery Report

Segmentasi Risiko Peminjam pada Dataset Lending Club
Penerapan proses Knowledge Discovery in Databases (KDD)

Field	Isi
Group Name	Kelompok 2
Dataset	Lending Club Loans (accepted_2007_to_2018Q4, Kaggle)
Domain Focus	Loan issuance, risk grading, borrower financial characteristics
Submission Date	[isi tanggal submit]
GitHub URL	[isi URL repo GitHub]

Student Name	Role
[Nama 1]	Data Engineer
[Nama 2]	Data Engineer
[Nama 3]	Pattern Analyst
[Nama 4]	Segmentation Specialist
[Nama 5]	Insight Communicator

Executive Summary

Analisis KDD atas 2.260.668 pinjaman Lending Club menemukan bahwa risiko gagal bayar terkonsentrasi pada segmen mayoritas: 62,2 persen peminjam berada dalam satu segmen dengan tingkat charged-off 14,4 persen, hampir dua kali lipat segmen prime (7,7 persen), dan segmen ini terpisah paling tajam pada kombinasi FICO, utilisasi revolving, dan ukuran pinjaman. Dua hal yang belum tercermin dalam praktik saat ini: grade internal hampir sepenuhnya cerminan suku bunga (hanya 1 dari 1.023 aturan asosiasi yang memprediksi Grade A tanpa suku bunga), dan outlier statistik justru didominasi nasabah affluent yang membayar lancar (bad-rate 8,7 persen vs populasi 13,1 persen). Bank sebaiknya mengkalibrasi harga dan limit pada kombinasi atribut tersebut, dan mengganti flag berbasis outlier dengan aturan kombinasi atribut tekanan kredit yang tervalidasi menaikkan risiko gagal bayar 1,47 kali (19,2 persen).

Dataset and Methodology

Dataset

Lending Club Accepted Loans 2007–2018Q4, diunduh dari Kaggle (kaggle.com/datasets/wordsforthewise/lending-club), domain peer-to-peer lending dan risiko kredit konsumen. Seluruh 2.260.668 record dipakai (151 kolom mentah; 12 fitur final setelah feature selection). Sampling hanya dilakukan untuk komputasi yang tidak feasible pada data penuh, selalu acak dan seeded (seed 42): mutual information 50.000 baris, UMAP 100.000, hierarchical clustering 12.000, dan Apriori 250.000.

Phase 1: Data Preprocessing

Pembersihan tidak menghapus kolom hanya karena proporsi kosongnya tinggi. Setiap kolom bermasalah lebih dulu diberi dugaan mekanisme (structural missing, data leakage pasca-origination, atau MAR temporal) dan diverifikasi terhadap data, lalu keputusan mengikuti mekanisme itu: kolom bulan-sejak-kejadian yang kosong karena peristiwanya belum pernah terjadi diisi sentinel 999 plus flag biner, kolom leakage dibuang, kolom dengan missing di atas 40 persen dibuang, sisanya diimputasi median/modus (mort_acc diimputasi berbasis grup total_acc). Sebanyak 33 baris duplikat/tanpa label dibuang. Transformasi mencakup ordinal encoding grade dan sub_grade, binning kuantil lima fitur kontinu untuk persiapan ARM, winsorization data-driven pada fitur kontinu ber-|skew| di atas 1 (dengan guard anti-collapse untuk fitur zero-inflated), log1p kondisional, dan standardisasi. Fitur nominal murni dibuang dari matriks clustering, bukan di-one-hot, karena one-hot mendistorsi jarak Euclidean pada clustering. Feature selection memakai dua metode: pemangkasan multikolinearitas ($|r|$ di atas 0,85) lalu mutual information terhadap grade; hasilnya 12 fitur final. PCA sembilan komponen (90 persen varians) menjadi masukan K-Means dan hierarchical; UMAP varian densMAP menjadi masukan DBSCAN.

Phase 2: Clustering

Tiga algoritma diterapkan: K-Means (MiniBatch) pada ruang PCA, hierarchical clustering, dan DBSCAN. Jumlah cluster ditetapkan dua setelah uji stabilitas lintas lima sample. Pada K=2, nilai Elbow (inertia rata-rata) adalah 369.751 dan Silhouette 0,161 (deviasi 0,010). Kurva inertia menurun mulus (369.751 pada K=2; 327.805 pada K=3; 305.776 pada K=4) tanpa siku yang menonjolkan K tertentu,

sedangkan Silhouette memilih K=2 secara konsisten (menang di 4 dari 5 sample), sehingga keputusan bertumpu pada Silhouette. Untuk hierarchical, linkage average dan single menghasilkan chaining (satu cluster raksasa plus singleton) sehingga linkage Ward dipilih (cophenetic correlation 0,360; cophenetic average/single lebih tinggi tetapi strukturnya degenerate). DBSCAN pada embedding densMAP memakai eps 0,503 dan min_samples 12, keduanya data-driven (knee k-distance; pembulatan ln n), menghasilkan 426 noise point (0,43 persen). Adjusted Rand Index K-Means terhadap hierarchical 0,365 (moderat).

Phase 3: Association Rule Mining

Variabel kontinu didiskretisasi memakai ambang berbasis domain, bukan kuantil sembarang: bracket resmi FICO, ambang DTI 43 persen dari aturan Qualified Mortgage, batas utilisasi revolving 30 persen rekomendasi biro kredit, serta tier pendapatan dan jumlah pinjaman kredit konsumen AS. Mining dijalankan pada sample acak seeded 250.000 baris (proporsi seluruh tahun origination terjaga). Apriori dengan minimum support 0,04 dan panjang itemset maksimum empat menghasilkan 1.947 frequent itemset, yang menurunkan 14.764 rule sebelum filtering. Setelah filter lift di atas 1,15 dan confidence di atas 0,5, tersisa 1.023 rule (6,9 persen) dengan rentang lift 1,15 sampai 5,35.

Phase 4: Anomaly Detection

Deteksi mencari tiga tipe outlier: point (ekstrem satu dimensi), contextual (janggal hanya secara multivariat), dan collective (region kepadatan rendah). Empat metode dengan ambang eksplisit: IQR pengali 3, Z-score ambang 3, jarak Mahalanobis pada persentil chi-square 99,9 persen, dan Isolation Forest dengan contamination 1 persen. Nilai contamination diuji terhadap alternatif data-driven berupa pencarian gap pada kurva skor anomali terurut: kurva terbukti mulus tanpa jurang yang stabil (gap terbesar jatuh pada 0,10 persen populasi dan berpindah lokasi saat window pencarian digeser), dan pilihan cutoff nyaris tidak mengubah hasil akhir karena corroboration minimal dua metode (115.195 berbanding 116.225 anomali terkonfirmasi), sehingga contamination 1 persen dipertahankan sebagai metode paling ketat di antara keempatnya. Deteksi berjalan pada data non-winsorized agar nilai asli tidak terhapus. Anomali terkonfirmasi bila ditandai minimal dua metode: dari 271.143 kandidat, 116.225 terkonfirmasi, lalu disilangkan dengan noise DBSCAN Phase 2.

Findings

Setiap temuan berasal dari fase berbeda, memuat angka dari analisis, tidak terlihat langsung dari data mentah, mengimplikasikan tindakan bank spesifik, dan menghindari klaim kausal.

Finding 1 — Risiko gagal bayar terkonsentrasi pada segmen mayoritas (Clustering)

62,2 persen peminjam berada di satu segmen dengan tingkat charged-off 14,4 persen, hampir dua kali lipat segmen prime (7,7 persen).

Evidence

Segmentasi K-Means membelah populasi menjadi dua. Cluster 0 (dinamai Higher-risk) mencakup 62,2 persen peminjam dengan tingkat charged-off 14,4 persen; Cluster 1 (Prime) mencakup 37,8 persen dengan charged-off 7,7 persen. Tingkat di sini dihitung dari status Charged Off saja (rata-rata

populasi 11,9 persen). Dalam satuan simpangan baku (selisih z-score antar cluster, konsisten dengan radar profil Phase 2), pembeda paling tajam adalah FICO (1,16 SD; 684 berbanding 723), disusul ukuran pinjaman (0,87 SD; 12 ribu berbanding 20 ribu dolar) dan utilisasi revolving (0,85 SD; 58 berbanding 37 persen); gap penghasilan besar secara nominal (63 ribu berbanding 102 ribu dolar) tetapi hanya 0,34 SD karena varians penghasilan sangat lebar.

Corroboration

Hierarchical clustering linkage Ward menghasilkan pembagian dua kelompok serupa (Adjusted Rand Index 0,365, moderat); tabel silang menempatkan mayoritas anggota pada sel yang bersesuaian. Silhouette 0,161 memang rendah, wajar untuk data sosial-ekonomi kontinu tanpa gap tajam, tetapi kestabilan pemisahan lintas lima sample memperkuat bahwa dua segmen ini nyata.

Business Implication

Intuisi umum menduga peminjam bermasalah adalah minoritas kecil. Data menunjukkan sebaliknya: hampir dua pertiga buku pinjaman berada di segmen yang lebih berisiko, dan risiko itu terbaca dari beberapa atribut sekaligus, bukan satu skor tunggal: utilisasi revolving dan ukuran pinjaman menambah pemisahan hampir sebesar FICO.

Recommended Action

Tim kebijakan kredit sebaiknya mengkalibrasi harga dan limit pada kombinasi FICO, utilisasi revolving, dan ukuran pinjaman, bukan FICO tunggal. Karena segmen Higher-risk berukuran besar, perbaikan kecil pada penetapan harga segmen ini berdampak jauh lebih besar pada kerugian portofolio dibanding menyaring minoritas ekor.

Finding 2 — Grade internal hampir sepenuhnya cerminan suku bunga (ARM)

Hanya 1 dari 1.023 rule yang memprediksi Grade A tanpa suku bunga, dan satu-satunya prediktornya adalah FICO 740–799 (confidence 57 persen, lift 2,99).

Evidence

Dari 1.023 rule retained, seluruh rule kuat menuju grade memuat kategori suku bunga; satu-satunya pengecualian adalah FICO Very Good (740–799) menuju Grade A dengan confidence 0,57 dan lift 2,99, dan FICO memang input langsung model grading. Rule berlift tertinggi (sampai 5,35) semuanya memetakan pasangan grade dan suku bunga, misalnya Grade A menuju suku bunga rendah pada confidence 1,00 (lift 4,00). Kombinasi atribut fundamental (DTI sehat, FICO baik, utilisasi rendah) berasosiasi dengan Grade A pada 56 rule mining-angle, tetapi selalu bersama kategori suku bunga.

Corroboration

Pola grade-suku bunga konsisten monoton di seluruh tingkat: Grade B dengan bunga medium (lift 2,92), Grade C dengan bunga tinggi (3,03), Grade D/E dengan bunga sangat tinggi (3,68–4,06), dengan confidence 0,73 sampai 1,00. Contoh rule pada dokumen soal yang melibatkan small_business tidak didukung data (0 rule), sehingga interpretasi dibangun dari rule aktual, bukan asumsi.

Business Implication

Grade Lending Club pada praktiknya adalah fungsi dari penetapan harga internal (dan FICO), bukan ringkasan independen kelayakan kredit. Memakai grade dan suku bunga bersamaan dalam model hilir berarti memasukkan informasi yang sama dua kali.

Recommended Action

Tim pemodelan risiko sebaiknya tidak memperlakukan grade sebagai fitur independen di samping suku bunga; modelkan langsung dari atribut fundamental peminjam (DTI, FICO, utilisasi, penghasilan) agar penilaian tidak mengulang keputusan harga yang sudah dibuat.

Finding 3 — Anomali statistik bukan penanda risiko, kecuali satu sub-kelompok (Anomaly Detection)

Anomali terkonfirmasi gagal bayar lebih jarang dari populasi (8,7 vs 13,1 persen), tetapi sub-kelompok high-stress berjumlah 11.358 baris gagal bayar 19,2 persen (1,47 kali populasi).

Evidence

Bad-rate di temuan ini memakai definisi luas (Charged Off, Default, dan Late; populasi 13,1 persen), berbeda dari Finding 1 yang memakai Charged Off saja. Anomali terkonfirmasi justru gagal bayar lebih jarang (8,7 persen) karena mayoritas outlier adalah peminjam berpenghasilan sangat tinggi atau berlimit kartu besar yang membayar lancar. Sub-kelompok high-stress dibentuk independen dari skor gabungan DTI, utilisasi revolving, utilisasi total, dan jumlah inquiry (tanpa menyentuh status pinjaman): 11.358 baris ini gagal bayar 19,2 persen.

Corroboration

Karena sub-kelompok dibentuk sebelum melihat outcome, angka 19,2 persen adalah validasi, bukan definisi berputar. Deteksi saling menguatkan lintas metode: dari 426 noise DBSCAN Phase 2, 68 persen ikut ditandai metode statistik atau Isolation Forest. Terpisah dari itu, 2.654 anomali terklasifikasi data error murni (misalnya penghasilan 110 juta dolar, atau DTI bernilai sentinel 999).

Business Implication

Menyaring nasabah hanya karena ia outlier statistik salah sasaran: kelompok itu justru berisi nasabah bernilai tinggi. Sinyal risiko sesungguhnya datang dari kombinasi atribut tekanan kredit, bukan dari status keanehan itu sendiri.

Recommended Action

Tim underwriting sebaiknya memakai kombinasi atribut high-stress (DTI, utilisasi, dan inquiry tinggi bersamaan) sebagai aturan flag untuk review manual, bukan menandai baris karena outlier. Baris data error dikoreksi atau dikeluarkan lebih dulu agar tidak mendistorsi model.

Limitations

Scope of outlier detection

Deteksi anomali berjalan pada 12 fitur numerik terpilih dan sebagian besar menemukan point outlier (115.978 dari 116.225); contextual murni (43) dan collective (204) sangat sedikit, sebagian karena

fitur finansial berekor berat pada dimensi tunggal, sebagian karena keterbatasan ruang fitur. Anomali yang hanya muncul pada fitur yang dibuang saat feature selection tidak tertangkap.

Correlation versus causation

Semua temuan bersifat asosiatif. Cluster Higher-risk berasosiasi dengan penghasilan rendah dan utilisasi tinggi, tetapi analisis ini tidak membuktikan sebab-akibat; kami melaporkan selisih tingkat, bukan efek kausal.

Dataset representativeness

Data hanya memuat pinjaman yang disetujui Lending Club 2007–2018 sehingga mengandung bias seleksi (pemohon ditolak tidak terlihat), mencakup kondisi ekonomi periode itu saja, dan grade/suku bunga mengikuti kebijakan internal Lending Club. Komputasi berat (MI, UMAP, hierarchical, Apriori) berjalan pada sample acak seeded, bukan data penuh. Seluruh langkah memakai seed tetap, tetapi K-Means, UMAP, dan Isolation Forest bergantung pada implementasi library, sehingga menjalankan ulang dengan versi paket berbeda dapat menggeser angka pada desimal terakhir tanpa mengubah struktur temuan; versi yang dipakai dicatat pada requirements-lock.txt.

What additional data would improve these findings

Data pemohon yang ditolak akan memperbaiki analisis seleksi; riwayat pembayaran bulanan memungkinkan analisis temporal yang lebih dalam daripada status akhir; indikator makroekonomi per periode origination membantu memisahkan risiko peminjam dari risiko siklus; dan atribut biro kredit yang lebih rinci memungkinkan penilaian risiko yang independen dari penetapan harga internal.

Appendix

Appendix A — Full Cluster Profiles

Cluster	Profil	Ukuran %	CO %	Income	FICO	Revol util	DTI	Loan amnt	Grade	Term	Emp len
0	Higher-risk	62.2	14.4	63,474	684	58.4	19.6	12,086	3.0	41.7	5.7
1	Prime	37.8	7.7	101,922	722	37.0	17.5	19,927	2.1	44.9	6.4

CO % = tingkat Charged Off (definisi sempit). Profil outlier DBSCAN (426 noise): income rata-rata 127.197 dolar, DTI 26,5, loan 22.090 dolar, charged-off 15,3 persen (populasi 11,9) — profil 'stretched high-earners'.

Appendix B — Association Rules (40 lift tertinggi)

Tabel lengkap 1.023 rule retained tersedia di data/processed/phase3_association_rules.csv, terurut menurun berdasarkan lift. Berikut 40 teratas.

Antecedent	Consequent	Supp	Conf	Lift
grade = Grade A + loan_amnt = Loan Small(<10k)	int_rate = IntRate Low + revol_util = Util Excellent(<30)	0.042	0.51	5.35
grade = Grade A + revol_util = Util Moderate(30-60)	fico_range_low = FICO Good(670-739) + int_rate = IntRate Low	0.058	0.77	4.83
grade = Grade A + revol_util = Util Excellent(<30)	int_rate = IntRate Low + loan_amnt = Loan Small(<10k)	0.042	0.52	4.81
int_rate = IntRate Low + revol_util = Util Moderate(30-60)	fico_range_low = FICO Good(670-739) + grade = Grade A	0.058	0.57	4.76
emp_length = Emp Long(8+) + grade = Grade A	home = Home MORTGAGE + int_rate = IntRate Low	0.051	0.65	4.72
fico_range_low = FICO VeryGood(740-799) + int_rate = IntRate Low	grade = Grade A	0.054	0.89	4.70
int_rate = IntRate Low + revol_util = Util Excellent(<30)	dti = DTI Healthy(<20) + grade = Grade A	0.060	0.63	4.70
annual_inc = Inc Low(<50k) + int_rate = IntRate High	grade = Grade C + loan_amnt = Loan Small(<10k)	0.047	0.53	4.69
annual_inc = Inc Low(<50k) + grade = Grade B	int_rate = IntRate Medium + loan_amnt = Loan Small(<10k)	0.047	0.52	4.59
int_rate = IntRate Low + purpose = credit_card	fico_range_low = FICO Good(670-739) + grade = Grade A	0.043	0.55	4.56
home = Home MORTGAGE + int_rate = IntRate Low + revol_util = Util Excellent(<30)	grade = Grade A	0.043	0.85	4.48
dti = DTI Healthy(<20) + int_rate = IntRate Low + revol_util = Util Excellent(<30)	grade = Grade A	0.060	0.84	4.46
int_rate = IntRate Low + loan_amnt = Loan Small(<10k) + revol_util = Util Excellent(<30)	grade = Grade A	0.042	0.84	4.45
grade = Grade A + loan_amnt = Loan Medium(10-25k)	annual_inc = Inc Mid(50-100k) + int_rate = IntRate Low	0.047	0.55	4.45
annual_inc = Inc Low(<50k) + int_rate = IntRate Medium	grade = Grade B + loan_amnt = Loan Small(<10k)	0.047	0.59	4.42
int_rate = IntRate Low + revol_util = Util	grade = Grade A	0.081	0.84	4.42

Excellent(<30)				
grade = Grade A + purpose = credit_card	fico_range_low = FICO Good(670-739) + int_rate = IntRate Low	0.043	0.71	4.40
grade = Grade A + revol_util = Util Excellent(<30)	dti = DTI Healthy(<20) + int_rate = IntRate Low	0.060	0.75	4.32
grade = Grade A + loan_amnt = Loan Medium(10-25k)	home = Home MORTGAGE + int_rate = IntRate Low	0.050	0.59	4.30
grade = Grade A + loan_amnt = Loan Medium(10-25k)	int_rate = IntRate Low + purpose = debt_consolidation	0.044	0.52	4.28
emp_length = Emp Long(8+) + grade = Grade A	annual_inc = Inc Mid(50- 100k) + int_rate = IntRate Low	0.041	0.52	4.18
emp_length = Emp Short(0-3) + grade = Grade A	dti = DTI Healthy(<20) + int_rate = IntRate Low	0.043	0.73	4.18
dti = DTI Healthy(<20) + int_rate = IntRate Low + purpose = credit_card	grade = Grade A	0.042	0.79	4.18
annual_inc = Inc Mid(50- 100k) + grade = Grade A	home = Home MORTGAGE + int_rate = IntRate Low	0.054	0.57	4.18
grade = Grade A + home = Home RENT	fico_range_low = FICO Good(670-739) + int_rate = IntRate Low	0.041	0.67	4.17
fico_range_low = FICO Good(670-739) + int_rate = IntRate Low + purpose = credit_card	grade = Grade A	0.043	0.79	4.16
dti = DTI Healthy(<20) + home = Home MORTGAGE + int_rate = IntRate Low	grade = Grade A	0.074	0.79	4.15
grade = Grade A + home = Home RENT	dti = DTI Healthy(<20) + int_rate = IntRate Low	0.045	0.72	4.15
grade = Grade A + revol_util = Util Moderate(30-60)	home = Home MORTGAGE + int_rate = IntRate Low	0.043	0.57	4.14
int_rate = IntRate Very High + loan_amnt = Loan Small(<10k)	grade = Grade D	0.045	0.60	4.14
grade = Grade A + loan_amnt = Loan Small(<10k)	dti = DTI Healthy(<20) + int_rate = IntRate Low	0.059	0.72	4.12
emp_length = Emp Short(0-3) + int_rate = IntRate Low	dti = DTI Healthy(<20) + grade = Grade A	0.043	0.55	4.11
int_rate = IntRate Low + purpose = credit_card	grade = Grade A	0.061	0.78	4.11
grade = Grade A + home = Home MORTGAGE	annual_inc = Inc Mid(50- 100k) + int_rate = IntRate Low	0.054	0.51	4.10
dti = DTI Healthy(<20) + int_rate = IntRate Low	grade = Grade A	0.134	0.77	4.07
grade = Grade A	dti = DTI Healthy(<20) + int_rate = IntRate Low	0.134	0.71	4.07
grade = Grade A + purpose = debt_consolidation	home = Home MORTGAGE + int_rate = IntRate Low	0.051	0.56	4.07
dti = DTI Healthy(<20) + fico_range_low = FICO Good(670-739) + int_rate = IntRate Low	grade = Grade A	0.084	0.77	4.07
home = Home MORTGAGE + int_rate = IntRate Low + loan_amnt = Loan Small(<10k)	grade = Grade A	0.040	0.77	4.07
grade = Grade A + loan_amnt = Loan Medium(10-25k)	fico_range_low = FICO Good(670-739) + int_rate = IntRate Low	0.055	0.65	4.07

Appendix C — Anomaly Detection Results (sampel per kategori)

Seluruh 116.225 anomali terkonfirmasi tersimpan di data/processed/phase4_anomalies.csv (kolom: flag per metode, skor Mahalanobis, risk score, tipe outlier, klasifikasi). Berikut record teratas per kategori menurut jarak Mahalanobis, dengan interpretasi bisnis per record.

Kategori	ID	Income	DTI	FICO	Util	Loan	Status	Met.	Tipe	Interpretasi bisnis
data_error	601124	110,000,000	0.01	695	83.5	30,000	Current	3	point	Salah entri income — koreksi / keluarkan
data_error	1673117	61,000,000	0.01	690	35.1	10,000	Current	3	point	Salah entri income — koreksi / keluarkan
data_error	539803	10,999,200	0.07	685	41.1	5,000	Fully Paid	3	point	Salah entri income — koreksi / keluarkan
data_error	1597133	9,930,475	0.19	670	65.4	16,000	Current	3	point	Salah entri income — koreksi / keluarkan
data_error	1413796	9,757,200	0.15	665	12.2	14,000	Current	4	point	Salah entri income — koreksi / keluarkan
data_error	735420	9,573,072	0.16	680	61.9	30,000	Late (31-120 days)	3	point	Salah entri income — koreksi / keluarkan
risk_signal	993566	97,000	37.89	695	90.9	13,000	Fully Paid	4	point	Tekanan kredit tinggi — review manual
risk_signal	1292889	45,000	14.67	695	892.3	3,500	Fully Paid	3	point	Tekanan kredit tinggi — review manual
risk_signal	1985463	357,985	23.38	730	97.6	35,000	Current	4	point	Tekanan kredit tinggi — review manual
risk_signal	1653516	45,000	19.12	650	52.6	7,000	Does not meet the credit pol	3	point	Tekanan kredit tinggi — review manual
risk_signal	1653707	17,000	6.99	655	59.1	5,100	Does not meet the credit pol	3	point	Tekanan kredit tinggi — review manual
risk_signal	1654082	27,228	14.85	660	0.0	3,000	Does not meet the credit pol	3	point	Tekanan kredit tinggi — review manual
rare_case	1608780	230,000	36.14	700	69.3	30,000	Current	4	point	Affluent & lancar — jangan tolak otomatis
rare_case	1224164	800,000	15.77	680	84.1	24,000	Current	4	point	Affluent & lancar — jangan tolak otomatis
rare_case	162652	950,000	25.63	695	94.2	30,625	Current	4	point	Affluent & lancar — jangan tolak otomatis
rare_case	1232193	1,600,000	12.25	760	66.3	28,000	Fully Paid	4	point	Affluent &

										lancar — jangan tolak otomatis
rare_case	579174	400,000	26.36	675	77.0	15,350	Late (31- 120 days)	3	point	Affluent & lancar — jangan tolak otomatis
rare_case	2175238	125,000	26.48	785	1.7	29,375	Current	4	point	Affluent & lancar — jangan tolak otomatis

Appendix D — Evaluation Metrics Summary

Metrik	Nilai
Silhouette Score (K-Means, K final = 2)	0,161 (± 0,010 lintas 5 sample)
Cophenetic Correlation (linkage Ward)	0,360
Adjusted Rand Index (K-Means vs Hierarchical)	0,365
Frequent itemset (Apriori, support ≥ 0,04)	1.947
Rule dihasilkan sebelum filtering	14.764
Rule dipertahankan setelah filter (lift > 1,15; conf > 0,5)	1.023
Lift tertinggi pada retained rules	5,35
Total kandidat anomali sebelum corroboration (≥1 metode)	271.143
Anomali terkonfirmasi (≥2 metode)	116.225
Precision/Recall flag risk_signal vs label outcome	Precision 19,2% (baseline populasi 13,1%; lift 1,47x) · Recall 0,74% · flag bersifat sangat selektif (0,50% populasi) dan tidak dioptimalkan sebagai classifier