

Knowledge Discovery Report

Segmentasi Risiko Peminjam pada Dataset Lending Club
Penerapan proses Knowledge Discovery in Databases (KDD)

Field	Isi
Group Name	Kelompok 2
Dataset	Lending Club Loans (accepted_2007_to_2018Q4, Kaggle)
Domain Focus	Loan issuance, risk grading, borrower financial characteristics
Submission Date	[isi tanggal submit]
GitHub URL	github.com/wilsonPhan02/lending-club-loans

Student Name	Role
[Nama 1]	Data Engineer
[Nama 2]	Data Engineer
[Nama 3]	Pattern Analyst
[Nama 4]	Segmentation Specialist
[Nama 5]	Insight Communicator

Executive Summary

Pertanyaan sentral proyek ini adalah apa yang ditemukan yang tidak terlihat langsung dari data mentah. Jawabannya: analisis KDD atas 2.260.668 pinjaman Lending Club menemukan bahwa risiko gagal bayar terkonsentrasi pada segmen mayoritas: 62,2 persen peminjam berada dalam satu segmen dengan tingkat charged-off 14,4 persen, hampir dua kali lipat segmen prime (7,7 persen), dan segmen ini terpisah paling tajam pada kombinasi FICO, utilisasi revolving, dan ukuran pinjaman. Dua hal yang belum tercermin dalam praktik saat ini: grade internal hampir sepenuhnya cerminan suku bunga (hanya 1 dari 1.023 aturan asosiasi yang memprediksi Grade A tanpa suku bunga), dan outlier statistik justru didominasi nasabah affluent yang membayar lancar (bad-rate 8,7 persen vs populasi 13,1 persen). Bank sebaiknya mengkalibrasi harga dan limit pada kombinasi atribut tersebut, dan mengganti flag berbasis outlier dengan aturan kombinasi atribut tekanan kredit yang tervalidasi menaikkan risiko gagal bayar 1,47 kali (19,2 persen).

Dataset and Methodology

Dataset

Lending Club Accepted Loans 2007–2018Q4, diunduh dari Kaggle (kaggle.com/datasets/wordsforthewise/lending-club), domain peer-to-peer lending dan risiko kredit konsumen. Seluruh 2.260.668 record dipakai (151 kolom mentah; 12 fitur final setelah feature selection). Sampling hanya dilakukan untuk komputasi yang tidak feasible pada data penuh, selalu acak dan seeded (seed 42): mutual information 50.000 baris, UMAP 100.000, hierarchical clustering 12.000, dan Apriori 250.000.

Phase 1: Data Preprocessing

Pembersihan tidak menghapus kolom hanya karena proporsi kosongnya tinggi. Setiap kolom bermasalah lebih dulu diberi dugaan mekanisme (structural missing, data leakage pasca-origination, atau MAR temporal) dan diverifikasi terhadap data, lalu keputusan mengikuti mekanisme itu: kolom bulan-sejak-kejadian yang kosong karena peristiwanya belum pernah terjadi diisi sentinel 999 plus flag biner, kolom leakage dibuang, kolom dengan missing di atas 40 persen dibuang, sisanya diimputasi median/modus (mort_acc diimputasi berbasis grup total_acc). Sebanyak 33 baris duplikat/tanpa label dibuang. Transformasi mencakup ordinal encoding grade dan sub_grade, binning kuantil lima fitur kontinu untuk persiapan ARM, winsorization data-driven pada fitur kontinu ber-|skew| di atas 1 (dengan guard anti-collapse untuk fitur zero-inflated), log1p kondisional, dan standardisasi. Fitur nominal murni dibuang dari matriks clustering, bukan di-one-hot, karena one-hot mendistorsi jarak Euclidean pada clustering. Feature selection memakai dua metode: pemangkasan multikolinearitas (|r| di atas 0,85) lalu mutual information terhadap grade; hasilnya 12 fitur final. PCA sembilan komponen (90 persen varians) menjadi masukan K-Means dan hierarchical; UMAP varian densMAP menjadi masukan DBSCAN.

Phase 2: Clustering

Tiga algoritma diterapkan: K-Means (MiniBatch) pada ruang PCA, hierarchical clustering, dan DBSCAN. Jumlah cluster ditetapkan dua setelah uji stabilitas lintas lima sample. Pada K=2, nilai Elbow (inertia rata-rata) adalah 369.751 dan Silhouette 0,161 (deviasi 0,010). Kurva inertia menurun mulus

(369.751 pada K=2; 327.805 pada K=3; 305.776 pada K=4) tanpa siku yang menonjolkan K tertentu, sedangkan Silhouette memilih K=2 secara konsisten (menang di 4 dari 5 sample), sehingga keputusan bertumpu pada Silhouette. Untuk hierarchical, linkage average dan single menghasilkan chaining (satu cluster raksasa plus singleton) sehingga linkage Ward dipilih (cophenetic correlation 0,360; cophenetic average/single lebih tinggi tetapi strukturnya degenerate). DBSCAN pada embedding densMAP memakai eps 0,503 dan min_samples 12, keduanya data-driven (knee k-distance; pembulatan $\ln n$), menghasilkan 426 noise point (0,43 persen). Adjusted Rand Index K-Means terhadap hierarchical 0,365 (moderat).

Phase 3: Association Rule Mining

Variabel kontinu didiskretisasi memakai ambang berbasis domain, bukan kuantil sembarang: bracket resmi FICO, ambang DTI 43 persen dari aturan Qualified Mortgage, batas utilisasi revolving 30 persen rekomendasi biro kredit, serta tier pendapatan dan jumlah pinjaman kredit konsumen AS. Mining dijalankan pada sample acak seeded 250.000 baris (proporsi seluruh tahun origination terjaga). Apriori dengan minimum support 0,04 dan panjang itemset maksimum empat menghasilkan 1.947 frequent itemset, yang menurunkan 14.764 rule sebelum filtering. Setelah filter lift di atas 1,15 dan confidence di atas 0,5, tersisa 1.023 rule (6,9 persen) dengan rentang lift 1,15 sampai 5,35.

Phase 4: Anomaly Detection

Deteksi mencari tiga tipe outlier: point (ekstrem satu dimensi), contextual (janggal hanya secara multivariat), dan collective (region kepadatan rendah). Empat metode dengan ambang eksplisit: IQR pengali 3, Z-score ambang 3, jarak Mahalanobis pada persentil chi-square 99,9 persen, dan Isolation Forest dengan contamination 1 persen. Nilai contamination diuji terhadap alternatif data-driven berupa pencarian gap pada kurva skor anomali terurut: kurva terbukti mulus tanpa jurang yang stabil (gap terbesar jatuh pada 0,10 persen populasi dan berpindah lokasi saat window pencarian digeser), dan pilihan cutoff nyaris tidak mengubah hasil akhir karena corroboration minimal dua metode (115.195 berbanding 116.225 anomali terkonfirmasi), sehingga contamination 1 persen dipertahankan sebagai metode paling ketat di antara keempatnya. Deteksi berjalan pada data non-winsorized agar nilai asli tidak terhapus. Anomali terkonfirmasi bila ditandai minimal dua metode: dari 271.143 kandidat, 116.225 terkonfirmasi, lalu disilangkan dengan noise DBSCAN Phase 2.

Findings

Ketiga temuan berikut adalah jawaban rinci atas pertanyaan sentral: masing-masing hanya muncul setelah penambangan dan tidak terbaca dari tabulasi maupun agregasi sederhana atas data mentah. Setiap temuan berasal dari fase berbeda, memuat angka dari analisis, mengimplikasikan tindakan bank spesifik, dan menghindari klaim kausal.

Finding 1 — Risiko gagal bayar terkonsentrasi pada segmen mayoritas (Clustering)

62,2 persen peminjam berada di satu segmen dengan tingkat charged-off 14,4 persen, hampir dua kali lipat segmen prime (7,7 persen).

Evidence

Segmentasi K-Means membelah populasi menjadi dua. Cluster 0 (dinamai Higher-risk) mencakup 62,2 persen peminjam dengan tingkat charged-off 14,4 persen; Cluster 1 (Prime) mencakup 37,8 persen dengan charged-off 7,7 persen. Tingkat di sini dihitung dari status Charged Off saja (rata-rata populasi 11,9 persen). Dalam satuan simpangan baku (selisih z-score antar cluster, konsisten dengan radar profil Phase 2), pembeda paling tajam adalah FICO (1,16 SD; 684 berbanding 723), disusul ukuran pinjaman (0,87 SD; 12 ribu berbanding 20 ribu dolar) dan utilisasi revolving (0,85 SD; 58 berbanding 37 persen); gap penghasilan besar secara nominal (63 ribu berbanding 102 ribu dolar) tetapi hanya 0,34 SD karena varians penghasilan sangat lebar.

Corroboration

Hierarchical clustering linkage Ward menghasilkan pembagian dua kelompok serupa (Adjusted Rand Index 0,365, moderat); tabel silang menempatkan mayoritas anggota pada sel yang bersesuaian. Silhouette 0,161 memang rendah, wajar untuk data sosial-ekonomi kontinu tanpa gap tajam, tetapi kestabilan pemisahan lintas lima sample memperkuat bahwa dua segmen ini nyata.

Business Implication

Intuisi umum menduga peminjam bermasalah adalah minoritas kecil. Data menunjukkan sebaliknya: hampir dua pertiga buku pinjaman berada di segmen yang lebih berisiko, dan risiko itu terbaca dari beberapa atribut sekaligus, bukan satu skor tunggal: utilisasi revolving dan ukuran pinjaman menambah pemisahan hampir sebesar FICO.

Recommended Action

Tim kebijakan kredit sebaiknya mengkalibrasi harga dan limit pada kombinasi FICO, utilisasi revolving, dan ukuran pinjaman, bukan FICO tunggal. Karena segmen Higher-risk berukuran besar, perbaikan kecil pada penetapan harga segmen ini berdampak jauh lebih besar pada kerugian portofolio dibanding menyaring minoritas ekor.

Finding 2 — Grade internal hampir sepenuhnya cerminan suku bunga (ARM)

Hanya 1 dari 1.023 rule yang memprediksi Grade A tanpa suku bunga, dan satu-satunya prediktornya adalah FICO 740–799 (confidence 57 persen, lift 2,99).

Evidence

Dari 1.023 rule retained, seluruh rule kuat menuju grade memuat kategori suku bunga; satu-satunya pengecualian adalah FICO Very Good (740–799) menuju Grade A dengan confidence 0,57 dan lift 2,99, dan FICO memang input langsung model grading. Rule berlift tertinggi (sampai 5,35) semuanya memetakan pasangan grade dan suku bunga, misalnya Grade A menuju suku bunga rendah pada confidence 1,00 (lift 4,00). Kombinasi atribut fundamental (DTI sehat, FICO baik, utilisasi rendah) berasosiasi dengan Grade A pada 56 rule mining-angle, tetapi selalu bersama kategori suku bunga.

Corroboration

Pola grade-suku bunga konsisten monoton di seluruh tingkat: Grade B dengan bunga medium (lift 2,92), Grade C dengan bunga tinggi (3,03), Grade D/E dengan bunga sangat tinggi (3,68–4,06), dengan confidence 0,73 sampai 1,00. Contoh rule pada dokumen soal yang melibatkan

small_business tidak didukung data (0 rule), sehingga interpretasi dibangun dari rule aktual, bukan asumsi.

Business Implication

Grade Lending Club pada praktiknya adalah fungsi dari penetapan harga internal (dan FICO), bukan ringkasan independen kelayakan kredit. Memakai grade dan suku bunga bersamaan dalam model hilir berarti memasukkan informasi yang sama dua kali.

Recommended Action

Tim pemodelan risiko sebaiknya tidak memperlakukan grade sebagai fitur independen di samping suku bunga; modelkan langsung dari atribut fundamental peminjam (DTI, FICO, utilisasi, penghasilan) agar penilaian tidak mengulang keputusan harga yang sudah dibuat.

Finding 3 — Anomali statistik bukan penanda risiko, kecuali satu sub-kelompok (Anomaly Detection)

Anomali terkonfirmasi gagal bayar lebih jarang dari populasi (8,7 vs 13,1 persen), tetapi sub-kelompok high-stress berjumlah 11.358 baris gagal bayar 19,2 persen (1,47 kali populasi).

Evidence

Bad-rate di temuan ini memakai definisi luas (Charged Off, Default, dan Late; populasi 13,1 persen), berbeda dari Finding 1 yang memakai Charged Off saja. Anomali terkonfirmasi justru gagal bayar lebih jarang (8,7 persen) karena mayoritas outlier adalah peminjam berpenghasilan sangat tinggi atau berlimit kartu besar yang membayar lancar. Sub-kelompok high-stress dibentuk independen dari skor gabungan DTI, utilisasi revolving, utilisasi total, dan jumlah inquiry (tanpa menyentuh status pinjaman): 11.358 baris ini gagal bayar 19,2 persen.

Corroboration

Karena sub-kelompok dibentuk sebelum melihat outcome, angka 19,2 persen adalah validasi, bukan definisi berputar. Deteksi saling menguatkan lintas metode: dari 426 noise DBSCAN Phase 2, 68 persen ikut ditandai metode statistik atau Isolation Forest. Terpisah dari itu, 2.654 anomali terklasifikasi data error murni (misalnya penghasilan 110 juta dolar, atau DTI bernilai sentinel 999).

Business Implication

Menyaring nasabah hanya karena ia outlier statistik salah sasaran: kelompok itu justru berisi nasabah bernilai tinggi. Sinyal risiko sesungguhnya datang dari kombinasi atribut tekanan kredit, bukan dari status keanehan itu sendiri.

Recommended Action

Tim underwriting sebaiknya memakai kombinasi atribut high-stress (DTI, utilisasi, dan inquiry tinggi bersamaan) sebagai aturan flag untuk review manual, bukan menandai baris karena outlier. Baris data error dikoreksi atau dikeluarkan lebih dulu agar tidak mendistorsi model.

Limitations

Scope of outlier detection

Deteksi anomali berjalan pada 12 fitur numerik terpilih dan sebagian besar menemukan point outlier (115.978 dari 116.225); contextual murni (43) dan collective (204) sangat sedikit. Dua batasan perlu dinyatakan terbuka. Pertama, outlier contextual tidak diuji di dalam tiap segmen: Mahalanobis dihitung terhadap centroid populasi, bukan terhadap centroid masing-masing cluster, sehingga record yang wajar secara global namun janggal di dalam segmennya sendiri tidak tertangkap. Kedua, tidak ada fitur agregat berbasis jendela waktu yang dibangun untuk deteksi collective, karena dataset bersifat satu-baris-per-pinjaman, bukan level transaksi; deteksi collective sepenuhnya bergantung pada region kepadatan rendah dari DBSCAN. Anomali yang hanya muncul pada fitur yang dibuang saat feature selection juga tidak tertangkap.

Correlation versus causation

Aturan asosiasi pada Phase 3 menegaskan ko-okurensi, bukan kausalitas. Dua tempat pada Bagian 3 paling mudah tergoda dibaca kausal. Pada Finding 1, kombinasi FICO rendah, utilisasi tinggi, dan pinjaman besar berasosiasi dengan charged-off 14,4 persen, tetapi arah pengaruhnya tidak diuji: utilisasi tinggi dapat menjadi penanda tekanan yang sudah ada, bukan penyebabnya. Pada Finding 3, sub-kelompok high-stress gagal bayar 1,47 kali lebih sering, namun skor tekanan kredit dan gagal bayar dapat sama-sama merupakan akibat dari kondisi keuangan yang tidak terukur di dataset ini. Yang dilaporkan adalah selisih tingkat kejadian, bukan efek kausal, dan tidak ada mekanisme yang diuji.

Dataset representativeness

Data hanya memuat pinjaman yang disetujui Lending Club 2007–2018 sehingga mengandung bias seleksi (pemohon ditolak tidak terlihat), mencakup kondisi ekonomi periode itu saja, terbatas pada pasar Amerika Serikat sehingga tidak dapat digeneralisasi ke pasar lain, dan grade/suku bunga mengikuti kebijakan internal Lending Club. Beberapa atribut yang akan memperkuat analisis tidak tersedia sama sekali dalam dataset: riwayat pembayaran bulanan, produk lain yang dimiliki peminjam, dan interaksi layanan. Komputasi berat (MI, UMAP, hierarchical, Apriori) berjalan pada sample acak seeded, bukan data penuh. Seluruh langkah memakai seed tetap, tetapi K-Means, UMAP, dan Isolation Forest bergantung pada implementasi library, sehingga menjalankan ulang dengan versi paket berbeda dapat menggeser angka pada desimal terakhir tanpa mengubah struktur temuan; versi yang dipakai dicatat pada requirements-lock.txt.

What additional data would improve these findings

Data pemohon yang ditolak akan memperbaiki analisis seleksi; riwayat pembayaran bulanan memungkinkan analisis temporal yang lebih dalam daripada status akhir; indikator makroekonomi per periode origination membantu memisahkan risiko peminjam dari risiko siklus; dan atribut biro kredit yang lebih rinci memungkinkan penilaian risiko yang independen dari penetapan harga internal.

Appendix

Appendix A — Full Cluster Profiles

Tiap profil memuat ukuran (n dan persentase), rata-rata $\pm$ simpangan baku seluruh 12 fitur numerik final, modus fitur kategorik, tingkat charged-off, dan aksi yang direkomendasikan. Populasi noise DBSCAN disertakan sebagai profil tersendiri sesuai ketentuan template.

Fitur / ukuran	Higher-risk (Cluster 0)	Prime (Cluster 1)	Noise DBSCAN (outlier)
n	1,407,028	853,640	426
% populasi	62.24	37.76	0.02
Charged-off %	14.4	7.7	15.3
grade	3.0 $\pm$ 1.2	2.1 $\pm$ 1.1	3.7 $\pm$ 1.8
annual_inc	63,474.5 $\pm$ 52,191.5	101,921.8 $\pm$ 168,000.8	127,196.5 $\pm$ 141,942.4
dti	19.6 $\pm$ 15.1	17.5 $\pm$ 12.3	26.5 $\pm$ 52.8
fico_range_low	684.1 $\pm$ 20.5	722.5 $\pm$ 35.7	701.8 $\pm$ 39.1
revol_util	58.4 $\pm$ 22.6	37.0 $\pm$ 22.0	55.7 $\pm$ 37.1
emp_length	5.7 $\pm$ 3.6	6.4 $\pm$ 3.6	4.8 $\pm$ 3.7
loan_amnt	12,086.5 $\pm$ 7,271.2	19,926.6 $\pm$ 9,913.3	22,089.6 $\pm$ 12,397.8
term	41.7 $\pm$ 10.2	44.9 $\pm$ 11.6	43.3 $\pm$ 11.0
bc_open_to_buy	3,968.7 $\pm$ 4,191.4	23,111.1 $\pm$ 21,248.9	19,344.4 $\pm$ 41,268.7
total_bc_limit	12,783.9 $\pm$ 9,259.4	39,948.0 $\pm$ 27,800.4	41,356.8 $\pm$ 51,181.8
all_util	62.3 $\pm$ 14.3	49.3 $\pm$ 16.5	66.8 $\pm$ 36.1
inq_last_6mths	0.6 $\pm$ 0.9	0.5 $\pm$ 0.8	1.1 $\pm$ 1.3
purpose (modus)	debt_consolidation	debt_consolidation	debt_consolidation
home_ownership (modus)	RENT	MORTGAGE	MORTGAGE
verification_status (modus)	Source Verified	Not Verified	Verified
addr_state (modus)	CA	CA	CA

Aksi yang direkomendasikan per profil:

Higher-risk — kalibrasi harga dan limit pada kombinasi FICO, utilisasi revolving, dan ukuran pinjaman; monitoring lebih rapat karena segmen ini memuat 62,2 persen buku pinjaman.

Prime — prioritaskan retensi dan penawaran produk premium; ruang risiko memungkinkan limit lebih longgar.

Noise DBSCAN — 426 peminjam berpenghasilan tinggi namun DTI dan utilisasi tinggi (profil 'stretched high-earners'); layak review manual, bukan penolakan otomatis.

Appendix B — Association Rules (40 lift tertinggi)

Tabel lengkap 1.023 rule retained tersedia di data/processed/phase3_association_rules.csv, terurut menurun berdasarkan lift. Berikut 40 teratas.

Antecedent	Consequent	Supp	Conf	Lift
grade = Grade A + loan_amnt = Loan Small(<10k)	int_rate = IntRate Low + revol_util = Util Excellent(<30)	0.042	0.51	5.35
grade = Grade A + revol_util = Util Moderate(30-60)	fico_range_low = FICO Good(670-739) + int_rate = IntRate Low	0.058	0.77	4.83
grade = Grade A + revol_util = Util Excellent(<30)	int_rate = IntRate Low + loan_amnt = Loan Small(<10k)	0.042	0.52	4.81
int_rate = IntRate Low + revol_util = Util Moderate(30-60)	fico_range_low = FICO Good(670-739) + grade = Grade A	0.058	0.57	4.76
emp_length = Emp Long(8+) + grade = Grade A	home = Home MORTGAGE + int_rate = IntRate Low	0.051	0.65	4.72
fico_range_low = FICO VeryGood(740-799) + int_rate = IntRate Low	grade = Grade A	0.054	0.89	4.70
int_rate = IntRate Low +	dti = DTI Healthy(<20) +	0.060	0.63	4.70

revol_util = Util Excellent(<30)	grade = Grade A			
annual_inc = Inc Low(<50k) + int_rate = IntRate High	grade = Grade C + loan_amnt = Loan Small(<10k)	0.047	0.53	4.69
annual_inc = Inc Low(<50k) + grade = Grade B	int_rate = IntRate Medium + loan_amnt = Loan Small(<10k)	0.047	0.52	4.59
int_rate = IntRate Low + purpose = credit_card	fico_range_low = FICO Good(670-739) + grade = Grade A	0.043	0.55	4.56
home = Home MORTGAGE + int_rate = IntRate Low + revol_util = Util Excellent(<30)	grade = Grade A	0.043	0.85	4.48
dti = DTI Healthy(<20) + int_rate = IntRate Low + revol_util = Util Excellent(<30)	grade = Grade A	0.060	0.84	4.46
int_rate = IntRate Low + loan_amnt = Loan Small(<10k) + revol_util = Util Excellent(<30)	grade = Grade A	0.042	0.84	4.45
grade = Grade A + loan_amnt = Loan Medium(10-25k)	annual_inc = Inc Mid(50- 100k) + int_rate = IntRate Low	0.047	0.55	4.45
annual_inc = Inc Low(<50k) + int_rate = IntRate Medium	grade = Grade B + loan_amnt = Loan Small(<10k)	0.047	0.59	4.42
int_rate = IntRate Low + revol_util = Util Excellent(<30)	grade = Grade A	0.081	0.84	4.42
grade = Grade A + purpose = credit_card	fico_range_low = FICO Good(670-739) + int_rate = IntRate Low	0.043	0.71	4.40
grade = Grade A + revol_util = Util Excellent(<30)	dti = DTI Healthy(<20) + int_rate = IntRate Low	0.060	0.75	4.32
grade = Grade A + loan_amnt = Loan Medium(10-25k)	home = Home MORTGAGE + int_rate = IntRate Low	0.050	0.59	4.30
grade = Grade A + loan_amnt = Loan Medium(10-25k)	int_rate = IntRate Low + purpose = debt_consolidation	0.044	0.52	4.28
emp_length = Emp Long(8+) + grade = Grade A	annual_inc = Inc Mid(50- 100k) + int_rate = IntRate Low	0.041	0.52	4.18
emp_length = Emp Short(0-3) + grade = Grade A	dti = DTI Healthy(<20) + int_rate = IntRate Low	0.043	0.73	4.18
dti = DTI Healthy(<20) + int_rate = IntRate Low + purpose = credit_card	grade = Grade A	0.042	0.79	4.18
annual_inc = Inc Mid(50- 100k) + grade = Grade A	home = Home MORTGAGE + int_rate = IntRate Low	0.054	0.57	4.18
grade = Grade A + home = Home RENT	fico_range_low = FICO Good(670-739) + int_rate = IntRate Low	0.041	0.67	4.17
fico_range_low = FICO Good(670-739) + int_rate = IntRate Low + purpose = credit_card	grade = Grade A	0.043	0.79	4.16
dti = DTI Healthy(<20) + home = Home MORTGAGE + int_rate = IntRate Low	grade = Grade A	0.074	0.79	4.15
grade = Grade A + home = Home RENT	dti = DTI Healthy(<20) + int_rate = IntRate Low	0.045	0.72	4.15
grade = Grade A + revol_util = Util Moderate(30-60)	home = Home MORTGAGE + int_rate = IntRate Low	0.043	0.57	4.14
int_rate = IntRate Very High + loan_amnt = Loan	grade = Grade D	0.045	0.60	4.14

Small(<10k)				
grade = Grade A + loan_amnt = Loan Small(<10k)	dti = DTI Healthy(<20) + int_rate = IntRate Low	0.059	0.72	4.12
emp_length = Emp Short(0-3) + int_rate = IntRate Low	dti = DTI Healthy(<20) + grade = Grade A	0.043	0.55	4.11
int_rate = IntRate Low + purpose = credit_card	grade = Grade A	0.061	0.78	4.11
grade = Grade A + home = Home MORTGAGE	annual_inc = Inc Mid(50- 100k) + int_rate = IntRate Low	0.054	0.51	4.10
dti = DTI Healthy(<20) + int_rate = IntRate Low	grade = Grade A	0.134	0.77	4.07
grade = Grade A	dti = DTI Healthy(<20) + int_rate = IntRate Low	0.134	0.71	4.07
grade = Grade A + purpose = debt_consolidation	home = Home MORTGAGE + int_rate = IntRate Low	0.051	0.56	4.07
dti = DTI Healthy(<20) + fico_range_low = FICO Good(670-739) + int_rate = IntRate Low	grade = Grade A	0.084	0.77	4.07
home = Home MORTGAGE + int_rate = IntRate Low + loan_amnt = Loan Small(<10k)	grade = Grade A	0.040	0.77	4.07
grade = Grade A + loan_amnt = Loan Medium(10-25k)	fico_range_low = FICO Good(670-739) + int_rate = IntRate Low	0.055	0.65	4.07

Appendix C — Anomaly Detection Results (sampel per kategori)

Seluruh 116.225 anomali terkonfirmasi tersimpan di data/processed/phase4_anomalies.csv. Kolom mengikuti ketentuan template: identitas record, metode yang menandainya, skor kunci, tipe outlier, dan interpretasi bisnis. Berikut record teratas per kategori menurut jarak Mahalanobis.

Record ID	Metode yang menandai	Skor kunci	Tipe outlier	Interpretasi bisnis
601124	IQR + Z-score + Mahalanobis	Maha d^2 1,020,019 risk 0.98	point	Salah entri income / DTI sentinel — koreksi atau keluarkan sebelum modeling
1673117	IQR + Z-score + Mahalanobis	Maha d^2 313,530 risk -2.83	point	Salah entri income / DTI sentinel — koreksi atau keluarkan sebelum modeling
539803	IQR + Z-score + Mahalanobis	Maha d^2 10,146 risk -4.26	point	Salah entri income / DTI sentinel — koreksi atau keluarkan sebelum modeling
1597133	IQR + Z-score + Mahalanobis	Maha d^2 8,156 risk -0.01	point	Salah entri income / DTI sentinel — koreksi atau keluarkan sebelum modeling
1413796	IQR + Z-score + Mahalanobis + IsoForest	Maha d^2 7,915 risk -2.47	point	Salah entri income / DTI sentinel — koreksi atau keluarkan sebelum modeling
735420	IQR + Z-score + Mahalanobis	Maha d^2 7,535 risk -0.67	point	Salah entri income / DTI sentinel — koreksi atau keluarkan sebelum modeling
993566	IQR + Z-score + Mahalanobis + IsoForest	Maha d^2 6,482 risk 4.66	point	Tekanan kredit tinggi (DTI, utilisasi, inquiry) — flag review manual underwriting
1292889	IQR + Z-score + Mahalanobis	Maha d^2 2,481 risk 33.18	point	Tekanan kredit tinggi (DTI, utilisasi, inquiry) — flag review manual underwriting
1985463	IQR + Z-score + Mahalanobis + IsoForest	Maha d^2 2,349 risk 6.31	point	Tekanan kredit tinggi (DTI, utilisasi, inquiry) — flag

				review manual underwriting
1653516	IQR + Z-score + Mahalanobis	Maha d ² 1,370 risk 36.75	point	Tekanan kredit tinggi (DTI, utilisasi, inquiry) — flag review manual underwriting
1653707	IQR + Z-score + Mahalanobis	Maha d ² 1,292 risk 35.02	point	Tekanan kredit tinggi (DTI, utilisasi, inquiry) — flag review manual underwriting
1654082	IQR + Z-score + Mahalanobis	Maha d ² 1,194 risk 32.06	point	Tekanan kredit tinggi (DTI, utilisasi, inquiry) — flag review manual underwriting
1608780	IQR + Z-score + Mahalanobis + IsoForest	Maha d ² 12,477 risk 3.17	point	Affluent, limit besar, mayoritas lancar — jangan tolak otomatis
1224164	IQR + Z-score + Mahalanobis + IsoForest	Maha d ² 8,549 risk 1.67	point	Affluent, limit besar, mayoritas lancar — jangan tolak otomatis
162652	IQR + Z-score + Mahalanobis + IsoForest	Maha d ² 6,110 risk 2.77	point	Affluent, limit besar, mayoritas lancar — jangan tolak otomatis
1232193	IQR + Z-score + Mahalanobis + IsoForest	Maha d ² 4,989 risk 0.70	point	Affluent, limit besar, mayoritas lancar — jangan tolak otomatis
579174	IQR + Z-score + Mahalanobis	Maha d ² 4,049 risk 3.10	point	Affluent, limit besar, mayoritas lancar — jangan tolak otomatis
2175238	IQR + Z-score + Mahalanobis + IsoForest	Maha d ² 3,071 risk -2.89	point	Affluent, limit besar, mayoritas lancar — jangan tolak otomatis

Appendix D — Evaluation Metrics Summary

Phase	Metrik	Nilai
Phase 1	Fitur setelah feature selection	12 dari 151 kolom mentah
Phase 1	Varians dipertahankan PCA (9 komponen)	91,5 persen
Phase 2	Elbow (inertia rata-rata) pada K final = 2	369.751
Phase 2	Silhouette Score (K-Means, K final = 2)	0,161 (± 0,010 lintas 5 sample)
Phase 2	Cophenetic Correlation (linkage Ward)	0,360
Phase 2	Adjusted Rand Index (K-Means vs Hierarchical)	0,365
Phase 2	Noise DBSCAN (eps 0,503; min_samples 12)	426 dari 100.000 (0,43 persen)
Phase 3	Frequent itemset (Apriori, support ≥ 0,04)	1.947
Phase 3	Rule dihasilkan sebelum filtering	14.764
Phase 3	Rule dipertahankan setelah filter (lift > 1,15; conf > 0,5)	1.023
Phase 3	Lift tertinggi pada retained rules	5,35
Phase 4	Total kandidat anomali sebelum corroboration (≥1 metode)	271.143
Phase 4	Anomali terkonfirmasi (≥2 metode)	116.225
Phase 4	Precision / Recall vs. label (flag risk_signal)	Precision 19,2 persen vs baseline populasi 13,1 persen (lift 1,47x) · Recall 0,74 persen dari batas atas 3,85 persen — flag hanya menandai 0,50 persen populasi (11.358 baris) sehingga recall maksimum yang mungkin memang 3,85 persen;

		capaian setara 19 persen dari batas atas itu. Flag ini aturan triase untuk kapasitas review manual, bukan classifier: memperluas cakupan ke seluruh 116.225 anomali justru menurunkan precision ke 8,7 persen, di bawah baseline.
--	--	---